

CSIdentify

Matching DNA. Finding Answers.

Presented by:

Kelompok 7



**Florecita
Natawirya**
18223040



**Darryl Rayhananta
Adenan**
18223042



**Fhatika Adhalisman
Ryanjani**
18223062



**Muhammad Refino
Ramadhan**
18223070

Masalah: Forensik Bergantung pada STR

CSIidentify dikembangkan sebagai prototipe edukatif bioinformatika yang menggabungkan analisis Short Tandem Repeats (STR) dan algoritma Smith-Waterman local alignment.



Pada **database DNA global**, terdapat

19,27 juta

profil pelaku tersimpan di NDIS/CODIS dan terus berkembang setiap tahunnya.

(FBI November 2025)

Sebanyak

781.492+

investigasi kriminal berhasil dibantu melalui CODIS hits

(FBI November 2025)

Sebesar

64,8%

sampel DNA dari TKP dinyatakan cocok dengan data pada database

(NDNAD UK 2023/2024)

Namun, sistemnya masih...

Tidak transparan

Manual & lambat

Tidak terstruktur

Minim edukasi



CSIidentify dikembangkan sebagai **prototipe edukatif** untuk menunjukkan hubungan antara **konsep biologi STR** dan **metode komputasi**. Sistem **menerima sampel DNA** dari tempat kejadian perkara (TKP), **mengekstraksi profil repeat** dengan regular expression, lalu **membandingkannya dengan database tersangka**. Program akan menghasilkan pipeline yang lengkap, yaitu profiling STR, perhitungan skor kandidat, validasi kemiripan fragmen menggunakan Smith-Waterman local alignment, dan visualisasi hasil melalui dashboard web statis.

Metode & Algoritma: Alur Pemrosesan DNA

CSIidentify menggabungkan ekstraksi profil **Short Tandem Repeats (STR)** menggunakan **Regular Expression** dan pencocokan fragmen DNA dengan algoritma **Smith-Waterman** untuk menghasilkan ranking kecocokan tersangka

Input Data

Sistem menerima input berupa sekuens DNA dari TKP dan data CSV berisi daftar tersangka.

Validasi Sekuens

Fungsi **compact_sequence**: Menghapus spasi (whitespace) dan mengubah seluruh karakter sekuens menjadi huruf kapital.

Fungsi **validate_dna_sequence**: Memastikan karakter yang masuk hanya A, C, G, T, dan N. Karakter N merepresentasikan basa yang tidak diketahui, sehingga sistem tetap fleksibel.

Ekstraksi & Perbandingan STR

Setiap marker STR dikonversi menjadi pola Regular Expression, seperti $(?:AGAT)^+$

Fungsi **find_repeat_runs**: Mencari semua pengulangan berurutan (run) pada sekuens TKP.

Fungsi **longest_consecutive_repeats**: Mengambil run yang paling panjang sebagai nilai profil STR. Yang dihitung adalah run tandem terpanjang, bukan jumlah total kemunculan marker di seluruh sekuens.

Local Alignment

Sistem Scoring
Menggunakan parameter match= +2, mismatch = -1, dan gap = -2

Skor dihitung berdasarkan identity dan query coverage untuk mencegah bias pada alignment yang terlalu pendek.

$$Alignmentsupport = \frac{IdentityQuery \times QueryCoverage}{100}$$

Kalkulasi Ranking

Skor STR
Dihitung dari persentase kecocokan jumlah marker repeat tersangka yang sama persis dengan sampel DNA dari TKP.

Skor Alignment
Bertindak sebagai validasi fragmen tambahan dan pendukung kecocokan.

$$Combined\ Score = 0,7 \times STR\ Score + 0,3 \times Alignment\ Support$$

Output

Mengeluarkan hasil berupa file JSON dan visualisasi di dasbor web statis.

Dataset: Penggunaan Data untuk Testing

CSIidentify menggunakan 2 sumber data yang digunakan untuk pengujian sistem. Sumber Data ini membutuhkan satu sama lain untuk menghasilkan analisis.

Gambaran Umum Dataset



crime_scene_dna.txt
Sampel DNA TKP
(123 bp)



suspect.csv
10 orang tersangka



File : crime_scene_dna.txt



Panjang : 123 bp



Merupakan Sekuens DNA hasil ekstraksi dari TKP yang akan dibentuk menjadi profil STR

GATTACAGTCCAGATAGATAGATAG
ATAGATAGATAGATCCAATGAATGA
ATGAATGGGTATCTATCTATCTATCT
ATCTATCTTGCTAGCTAGCTAACTCT
ATCTATCTATCTATCTACAGT



File : suspect.csv



Jumlah Kandidat : 10



Setiap kandidat memiliki:

- Nama
- Profil repeat STR (5 marker)
- Sekuens DNA sintesis



10
Kandidat


Format & Struktur Data

Data	Format File	Struktur/Isi
Sampel DNA TKP	.txt	Sekuens DNA mentah (123 bp)
Database Tersangka	.csv	Nama, 5 marker STR, Sekuens DNA sintesis
Output Sistem	.json + web	Ranking, trace RegEx, alignment, ringkasan visual

Marker STR

AGAT	AATG	TATC	GCTA	TCTA
------	------	------	------	------

Alur Data Ke Sistem



Hasil Pengujian: Analisis dan Interpretasi

CSIidentify mengekstraksi profil STR dari DNA TKP menggunakan RegEx, lalu memvalidasi kemiripan DNA dengan Smith-Waterman local alignment.


PRIMARY MATCH IDENTIFIED

Bagas Pratama 100% MATCH

Marker cocok: 5/5 | STR: 100% | Alignment: 100% | Distance: 0

100%


Ranking Kecocokan berdasarkan combined score tersangka



Profil STR TKP

Repeat terpanjang hasil scanning RegEx yang akan dicocokkan dengan DNA milik tersangka.

AGAT = 7 GCTA = 3
AATG = 4 TCTA = 5
TATC = 6



Near Match

Skor tersangka lain turun karena ada **selisih repeat pada marker STR**

- Joko Wibowo: 85.05%
- Eka Putra: 85.03%
- Alya Salsabila: 84.05%



Interpretasi Hasil

Profil Bagas Pratama cocok 5/5 marker dengan DNA TKP, memiliki distance 0, serta alignment 100% sehingga dinyatakan sebagai Tersangka Utama dalam kasus ini

A stylized DNA double helix structure is shown, rendered in a translucent, golden-brown color. The helix is positioned diagonally across the frame, with its base pairs represented by small, pill-shaped structures. The background is a gradient of blue on the left and red on the right, with a soft, out-of-focus light effect in the center. The text "Thank You" is written in a white, sans-serif font, preceded by a vertical bar, and is located in the lower right quadrant of the image.

| Thank You