

Tugas Besar
IF3211 Komputasi Domain Spesifik

**Analisis DNA Forensik Berbasis Short Tandem
Repeats (STR) dengan RegEx**



Disusun oleh :

Kelompok 07 - K05

Florecita Natawirya (18223040)

Darryl Rayhananta Adenan (18223042)

Fhatika Adhalisman Ryanjani (18223062)

Muhammad Refino Ramadhan (18223070)

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
JLN. GANESHA 10, BANDUNG 40132
2026

BAB I Pendahuluan

1.1 Konsep Biologi Terkait

DNA menyimpan informasi genetik dalam urutan basa *adenine* (A), *cytosine* (C), *guanine* (G), dan *thymine* (T). Dalam identifikasi manusia, salah satu pendekatan yang banyak digunakan adalah analisis *Short Tandem Repeats* (STR), yaitu motif DNA pendek yang berulang secara berurutan pada lokus tertentu. Jumlah ulangan pada daerah STR dapat berbeda antarindividu sehingga pola *repeat* dapat dipakai sebagai profil identifikasi. National Institute of Justice menjelaskan bahwa teknologi STR mengevaluasi daerah spesifik pada DNA nuklir dan sifat polimorfiknya meningkatkan kemampuan diskriminasi antarprofil DNA [2].

1.2 Metode Komputasi Terkait

CSIdentify dikembangkan sebagai prototipe edukatif untuk menunjukkan hubungan antara konsep biologi STR dan metode komputasi. Sistem menerima sampel DNA dari tempat kejadian perkara (TKP), mengekstraksi profil repeat dengan regular expression, lalu membandingkannya dengan *database* tersangka. Program akan menghasilkan *pipeline* yang lengkap, yaitu *profiling* STR, perhitungan skor kandidat, validasi kemiripan fragmen menggunakan *Smith-Waterman local alignment*, dan visualisasi hasil melalui *dashboard* web statis.

1.3 Tinjauan Pustaka Karya

FBI CODIS menggunakan lokus STR sebagai dasar pengelolaan profil DNA pada sistem indeks nasional, sedangkan literatur forensik menekankan bahwa STR menjadi metode utama *human identity testing* karena variasinya tinggi di antara individu [1][5]. Dari sisi komputasi, Smith dan Waterman memperkenalkan algoritma *local alignment* berbasis *dynamic programming* untuk menemukan subsekuens molekuler yang paling mirip [3]. Prinsip *local alignment* juga menjadi dasar konseptual bagi pencarian kemiripan sekuens seperti BLAST, yang mencari *region of local similarity* antara sekuens biologis [4].

1.4 Rumusan Pertanyaan Penelitian

Bagaimana menggabungkan profil STR dan *local sequence alignment* untuk *me-ranking* tersangka dari sampel DNA TKP secara transparan dan dapat diaudit?

1.5 Tujuan/Kontribusi Penelitian

1. Menghasilkan program Python yang mampu membaca DNA TKP dan *database* tersangka.
2. Memvalidasi input sekuens.
3. Mengekstraksi profil STR.
4. Menghitung *ranking* tersangka.
5. Melakukan *local alignment*.
6. Menyimpan hasil dalam JSON.
7. Menyediakan *dashboard* web untuk membantu presentasi hasil.

Kontribusi objektifnya adalah menjadi *mini-tool* bioinformatika forensik yang dapat memperlihatkan proses dari data mentah hingga keputusan kandidat secara runtut.

BAB II Metode

2.1 Metode Komputasi

Tautan kode program: <https://github.com/darrylrayhananta/CSIdentify>

2.1.1 Dataset dan Input

Input sistem terdiri atas dua berkas utama, yaitu `crime_scene_dna.txt` sebagai sampel DNA TKP dan `suspects.csv` sebagai database tersangka. Sampel DNA TKP pada pengujian demo memiliki panjang 123 bp. Database tersangka berisi 10 kandidat dengan kolom nama, lima *marker* STR (AGAT, AATG, TATC, GCTA, TCTA), dan kolom `DNA_Sequence` yang digunakan untuk validasi *alignment* lokal. Format ini membuat sistem dapat membandingkan profil numerik STR sekaligus fragmen sekuens mentah.

Komponen	Ukuran/Jumlah	Keterangan
Crime scene DNA	123 bp	Sekuens DNA TKP yang diekstraksi menjadi profil STR
Marker STR	5 marker	AGAT, AATG, TATC, GCTA, dan TCTA
Database tersangka	10 kandidat	Setiap kandidat memiliki profil repeat dan sekuens DNA sintetis
Output	JSON + web	Hasil ranking, trace RegEx, alignment, dan ringkasan visual


2.1.2 Validasi dan Normalisasi Sekuens

Fungsi `compact_sequence` menghapus *whitespace* dan mengubah input menjadi huruf besar. Setelah itu, `validate_dna_sequence` menolak karakter selain A, C, G, T, dan N. Validasi ini penting karena algoritma pencarian pola dan alignment bergantung pada alfabet DNA yang konsisten. Karakter N diperbolehkan sebagai representasi basa tidak diketahui sehingga input tetap fleksibel untuk simulasi data biologis yang tidak sepenuhnya bersih.

2.1.3 Ekstraksi Profil STR dengan RegEx

Setiap *marker* STR dikonversi menjadi pola *regular expression* berbentuk `(?:MARKER)+`. Contohnya, marker AGAT menjadi pola `(?:AGAT)+`. Fungsi `find_repeat_runs` mencari semua *run* berurutan pada sekuens TKP, menyimpan posisi awal, posisi akhir, *matched sequence*, *pattern*, dan jumlah *repeat*. Fungsi `longest_consecutive_repeats` kemudian mengambil *repeat* terpanjang sebagai nilai profil STR marker tersebut. Dengan cara ini, sistem tidak menjumlahkan semua kemunculan marker, tetapi hanya menghitung *run* tandem terpanjang sesuai konsep STR.

2.1.4 Smith-Waterman Local Alignment



Setelah profil STR dihitung, sistem menjalankan Smith-Waterman *local alignment* untuk kandidat yang memiliki `DNA_Sequence`. *Local alignment* dipilih karena sampel forensik dapat berupa fragmen sehingga sistem lebih tepat mencari bagian sekuens yang paling mirip daripada memaksa seluruh sekuens sejajar secara global. Skor yang digunakan adalah $\text{match} = +2$, $\text{mismatch} = -1$, dan $\text{gap} = -2$. Matriks *dynamic programming* diisi dengan nilai maksimum dari 0, diagonal, atas, dan kiri, dengan nilai 0 memungkinkan *alignment* dimulai ulang ketika skor lokal menjadi buruk.

Hasil *alignment* mencakup skor mentah, *aligned query*, *aligned subject*, *match line*, posisi mulai dan akhir, jumlah *matches*, *mismatches*, *gaps*, *identity percent*, *query coverage*, dan *subject coverage*. Untuk mencegah *alignment* pendek tampak terlalu kuat, sistem menghitung dukungan *alignment* sebagai *identity* dikalikan *query coverage*, dengan rumus sebagai berikut,

$$\text{Alignment support} = \frac{\text{Identity Query} \times \text{Query Coverage}}{100}$$

2.2 Implementasi Sistem

2.2.1 Komponen Program

Implementasi inti berada pada file `csidentify.py`. Modul ini tidak hanya menyediakan CLI, tetapi juga memisahkan logika utama ke beberapa fungsi agar mudah diuji. Struktur ini terlihat dari adanya *unit test* pada `test_csidentify.py` yang menguji *repeat counting*, validasi *marker*, pembacaan CSV, *local alignment*, *ranking*, *output JSON*, dan mode interaktif. *Dashboard* `index.html` berfungsi sebagai antarmuka web statis untuk *upload* DNA TKP dan CSV tersangka, lalu menampilkan hasil analisis dalam bentuk kartu ringkasan, *chart*, tabel *ranking*, *alignment*, dan *trace* RegEx.

File	Peran	Isi/Fungsi
<code>csidentify.py</code>	Modul utama Python	Validasi DNA, RegEx STR, Smith-Waterman, ranking, CLI, dan output JSON
<code>test_csidentify.py</code>	<i>Unit test</i>	Menguji fungsi inti seperti longest repeat, load CSV, alignment, dan ranking
<code>crime_scene_dna.txt</code>	Input demo	Sampel DNA TKP sintetis sepanjang 123 bp
<code>suspects.csv</code>	<i>Database</i> demo	10 tersangka dengan profil STR dan DNA Sequence
<code>analysis_result.json</code>	Output analisis	Hasil terstruktur untuk dokumentasi dan validasi
<code>index.html</code>	<i>Dashboard</i> web	Visualisasi hasil, upload file, chart, ranking, dan trace

2.2.2 Logika Ranking

Ranking tersangka dihitung dari dua sumber skor. Pertama, skor STR dihitung sebagai persentase *marker* yang *repeat*-nya sama persis dengan profil DNA TKP. Kedua, skor *alignment* dihitung dari dukungan Smith-Waterman yang mempertimbangkan *identity* dan *coverage*. Skor akhir menggunakan bobot 70% STR dan 30% *alignment*. Pemilihan bobot ini masuk akal untuk simulasi forensik karena profil STR menjadi bukti utama, sedangkan *alignment* berfungsi sebagai validasi fragmen tambahan.

Rumus yang digunakan adalah:

$$\text{Combined Score} = 0,7 \times \text{STR Score} + 0,3 \times \text{Alignment Support}$$

2.2.3 Trace dan Audibilitas

Salah satu kekuatan program adalah adanya `processing_trace` pada output JSON. Untuk setiap *marker*, *trace* menyimpan *pattern* RegEx, daftar *run* yang ditemukan, posisi *start-end*, *matched sequence*, dan *longest repeat*. Untuk setiap tersangka, *trace* menyimpan *marker* yang cocok, catatan perbedaan, *score percent*, *combined score*, *distance*, status *exact match*, dan *alignment*. Informasi ini penting karena pengguna dapat menelusuri alasan sistem memilih kandidat tertentu, bukan hanya menerima hasil akhir sebagai *black box*.

2.2.4 Pengujian Program

Unit test memperlihatkan bahwa beberapa risiko kesalahan sudah diantisipasi. Misalnya, `longest_consecutive_repeats` diuji agar menghitung run terpanjang, bukan total kemunculan *marker*. Fungsi `find_repeat_runs` juga diuji agar *marker* yang memiliki karakter khusus RegEx tetap di-escape dengan benar. Smith-Waterman diuji menggunakan dua sekuens yang memiliki *region* AGATAGAT sebagai *local match* terbaik. Selain itu, mode interaktif diuji agar menghasilkan output JSON dan selalu menampilkan jejak *processing*.

- *Test repeat counting* memastikan AGATAGAT dan AGATAGATAGATAGAT tidak disalahartikan sebagai total *repeat* yang sama.
- *Test alignment* membuktikan *local alignment* dapat menemukan *region* terbaik walaupun ada basa tambahan di awal atau akhir.
- *Test ranking* membuktikan *alignment* dapat menjadi pembeda ketika profil STR beberapa kandidat sama atau sangat dekat.
- *Test output* memastikan sistem menghasilkan `analysis_result.json` sebagai artefak dokumentasi.

BAB III Hasil & Diskusi

3.1 Hasil Kuantitatif

3.1.1 Profil DNA TKP


Marker STR	Repeat Terpanjang	Interpretasi
AGAT	7	Run tandem terpanjang pada DNA TKP
AATG	4	Run tandem terpanjang pada DNA TKP
TATC	6	Run tandem terpanjang pada DNA TKP
GCTA	3	Run tandem terpanjang pada DNA TKP
TCTA	5	Run tandem terpanjang pada DNA TKP

Profil DNA TKP yang terbentuk adalah AGAT=7, AATG=4, TATC=6, GCTA=3, dan TCTA=5. Nilai ini berasal dari *run* terpanjang pada masing-masing *marker*. Sebagai contoh, *marker* AGAT ditemukan pada posisi 11-39 dengan tujuh pengulangan berurutan. *Marker* TATC memiliki dua *run*, yaitu *repeat* 6 dan *repeat* 4; sistem memilih *repeat* 6 karena STR profile direpresentasikan oleh *repeat* maksimum pada *marker* tersebut.

3.1.2 Ranking Tersangka

Rank	Tersangka	Cocok	STR	Align	Combined	Jarak	Selisih Marker
1	Bagas Pratama	5/5	100.00%	100.00%	100.00%	0	-
2	Joko Wibowo	4/5	80.00%	96.85%	85.05%	1	AGAT: +1
3	Eka Putra	4/5	80.00%	96.75%	85.03%	1	TATC: -1
4	Alya Salsabila	4/5	80.00%	93.50%	84.05%	2	AGAT: -2
5	Farah Nabila	3/5	60.00%	93.50%	70.05%	2	AGAT: -1, GCTA: -1
6	Gilang Ramadhan	3/5	60.00%	90.25%	69.08%	2	AATG: -1, TCTA: -1
7	Citra Maheswari	2/5	40.00%	77.24%	51.17%	6	AATG: -2, TATC: -1, TCTA: -3
8	Hana Lestari	0/5	0.00%	82.11%	24.63%	9	AGAT: -3, AATG: +1, TATC: -3, GCTA: -1, TCTA: +1
9	Dewi Anggraini	0/5	0.00%	76.00%	22.80%	16	AGAT: -6, AATG: +2, TATC: -4, GCTA: +2, TCTA: +2
10	Indra Saputra	0/5	0.00%	53.02%	15.91%	14	AGAT: -5, AATG: -3, TATC: +1, GCTA: +1, TCTA: -4

Hasil tertinggi adalah Bagas Pratama dengan 5/5 *marker* cocok, skor STR 100%, *alignment* support 100%, *combined score* 100%, dan jarak 0. Hasil ini menunjukkan kecocokan sempurna pada level profil STR dan sekuens lokal. Kandidat kedua dan ketiga, Joko Wibowo dan Eka Putra, sama-sama memiliki 4/5 *marker* cocok dan jarak 1, tetapi urutannya dibedakan oleh *alignment support*: Joko Wibowo 96,85% dan Eka Putra 96,75%. Selisih ini kecil, namun memperlihatkan fungsi *alignment* sebagai *tie breaker* tambahan.



3.2 Diskusi Kualitatif

3.2.1 Interpretasi Biologis

Secara biologis, kecocokan lima marker STR pada Bagas Pratama berarti profil *repeat* pada *database* tersangka sama dengan profil yang diekstraksi dari DNA TKP. Dalam model edukatif ini, kondisi tersebut diberi label *exact match*. Kandidat lain yang hanya memiliki empat marker cocok tetap memiliki kemiripan cukup tinggi, tetapi satu perbedaan *repeat* sudah cukup menurunkan skor STR menjadi 80%. Hal ini selaras dengan prinsip bahwa variasi jumlah *repeat* pada lokus STR menjadi dasar pembeda antarindividu.

Perbedaan *marker* dapat ditafsirkan sebagai perbedaan panjang *region tandem repeat*. Joko Wibowo memiliki AGAT=8, sedangkan TKP memiliki AGAT=7, sehingga terdapat satu *repeat* tambahan pada marker AGAT. Eka Putra memiliki TATC=5, sedangkan TKP memiliki TATC=6, sehingga terdapat satu *repeat* lebih sedikit pada marker TATC. Alya Salsabila memiliki AGAT=5 atau dua *repeat* lebih sedikit dari TKP. Perbedaan tersebut tercermin pada *distance* yang makin besar ketika selisih *repeat* bertambah.

3.2.2 Peran Local Alignment

Smith-Waterman membantu menguji apakah fragmen DNA tersangka masih memiliki kemiripan sekuens dengan DNA TKP. Pada Bagas Pratama, alignment mencakup 123 bp dengan 123 matches, 0 mismatches, 0 gaps, identity 100%, dan coverage 100%. Pada Joko Wibowo, alignment tetap memiliki 123 matches, tetapi terdapat 4 gaps karena sekuens tersangka memuat satu *repeat* AGAT tambahan. Kondisi ini menjelaskan mengapa skor alignment masih tinggi, tetapi profil STR tidak *exact match*.

Hasil Farah Nabila menarik karena *alignment support* mencapai 93,50%, tetapi skor STR hanya 60%. Ini menunjukkan bahwa kemiripan sekuens lokal saja tidak cukup untuk menyatakan kecocokan forensik dalam simulasi ini. Profil STR tetap diberi bobot lebih besar karena marker *repeat* adalah fitur utama yang dipakai sistem. Dengan demikian, pembobotan 70:30 menjaga agar ranking tidak terlalu dipengaruhi oleh fragmen panjang yang tampak mirip tetapi memiliki perbedaan *repeat* penting.

3.2.3 Kekuatan Sistem

- *Pipeline end-to-end* jelas: input, validasi, profiling STR, alignment, ranking, output JSON, dan dashboard.
- Hasil kuantitatif mudah dibaca karena ada *matching markers*, *distance*, *STR score*, *alignment support*, dan *combined score*.
- *Trace RegEx* membuat proses ekstraksi profil TKP transparan dan cocok untuk demonstrasi pembelajaran.
- *Unit test* menunjukkan fungsi inti sudah diuji pada beberapa kasus penting, termasuk *local alignment* dan *parsing CSV*.
- *Dashboard* web membantu presentasi karena menampilkan ringkasan, grafik, tabel *ranking*, *alignment*, dan *trace*

3.2.4 Keterbatasan Sistem

- *Dataset* masih sintesis dan belum memakai lokus STR forensik nyata seperti CODIS core loci.
- Model *repeat* masih sederhana karena setiap marker direpresentasikan satu angka, belum memodelkan alel diploid.
- Belum ada probabilitas populasi, *random match probability*, *likelihood ratio*, atau interpretasi statistik forensik.
- Belum menangani *mixture* DNA, degradasi parah, kontaminasi, *stutter*, *peak height*, dan artefak elektroferogram.
- Smith-Waterman $O(mn)$ cocok untuk demo pendek, tetapi perlu optimasi atau *library* bioinformatika untuk dataset besar.

BAB IV Kesimpulan

4.1 Kesimpulan

CSIdentify berhasil memenuhi tujuan proyek *DNA Sequence Analysis & Sequence Alignment* melalui implementasi Python yang menggabungkan analisis STR dan *local sequence alignment*. Sistem dapat memvalidasi sekuens DNA, mengekstraksi *repeat* terpanjang dari lima *marker* STR, membandingkan profil DNA TKP dengan 10 tersangka, menjalankan Smith-Waterman *local alignment*, menghitung *combined score*, dan menghasilkan *output* JSON serta *dashboard* web. Pada *dataset* uji, sistem mengidentifikasi Bagas Pratama sebagai kandidat paling konsisten dengan DNA TKP karena semua *marker* cocok dan *alignment* menunjukkan *identity* serta *coverage* 100%.

Kontribusi objektif proyek ini adalah menyediakan prototipe pembelajaran yang menjembatani konsep biologi molekuler dan komputasi. Dari sisi biologi, sistem menjelaskan bagaimana motif STR dapat menjadi pembeda profil DNA. Dari sisi komputasi, sistem memperlihatkan pemanfaatan RegEx untuk pencarian motif, *dynamic programming* untuk *alignment* lokal, serta pembobotan skor untuk *ranking* kandidat. Dengan *trace processing*, sistem juga lebih mudah diaudit dibanding program yang hanya memberi *output* akhir.

4.2 Saran Pengembangan

- Mengganti marker sintetis dengan *marker* STR forensik nyata dan menambahkan metadata lokus.
- Merepresentasikan tiap *marker* sebagai dua alel agar lebih dekat dengan profil DNA manusia yang diploid.
- Menambahkan perhitungan statistik seperti *random match probability* atau *likelihood ratio*.
- Mendukung input FASTA/FASTQ agar sistem dapat membaca format bioinformatika yang lebih umum.
- Membandingkan hasil Smith-Waterman dengan BLAST atau *library* seperti Biopython untuk evaluasi performa.
- Menambahkan visualisasi matriks *alignment* dan ringkasan perbedaan marker pada *dashboard* web.

Daftar Pustaka

- [1] FBI. (n.d.). CODIS and NDIS Fact Sheet. Federal Bureau of Investigation. <https://www.fbi.gov/how-we-can-help-you/dna-fingerprint-act-of-2005-expungement-policy/codis-and-ndis-fact-sheet>
- [2] National Institute of Justice. (2012). DNA Evidence: Basics of Analyzing. <https://nij.ojp.gov/topics/articles/dna-evidence-basics-analyzing>
- [3] Smith, T. F., & Waterman, M. S. (1981). Identification of common molecular subsequences. Journal of Molecular Biology, 147(1), 195-197. [https://doi.org/10.1016/0022-2836\(81\)90087-5](https://doi.org/10.1016/0022-2836(81)90087-5)
- [4] National Center for Biotechnology Information. (n.d.). BLAST: Basic Local Alignment Search Tool. <https://blast.ncbi.nlm.nih.gov/Blast.cgi>
- [5] Butler, J. M. (2005). Forensic DNA Typing: Biology, Technology, and Genetics of STR Markers. Elsevier Academic Press.
- [6] Altschul, S. F., Gish, W., Miller, W., Myers, E. W., & Lipman, D. J. (1990). Basic local alignment search tool. Journal of Molecular Biology, 215(3), 403-410. [https://doi.org/10.1016/S0022-2836\(05\)80360-2](https://doi.org/10.1016/S0022-2836(05)80360-2)
- [7] CSIdentify Project Files. (2026). csidentify.py, test_csidentify.py, suspects.csv, crime_scene_dna.txt, and analysis_result.json.

Lampiran

Link Repository GitHub : <https://github.com/darrylrayhananta/CSIdentify>
Link Website : <https://csidentify.vercel.app/>
Link Video Presentasi : <https://youtu.be/bXs0WNmRoPw>
Link PPT Presentasi :  IF3211_PPT_Kelompok 7

Pembagian Tugas Anggota

NIM - Nama	Kontribusi
18223040 - Florecita Natawirya	• Membuat laporan • Mengerjakan PPT
18223042 - Darryl Rayhananta Adenan	• Membuat front-end website • Mengerjakan PPT
18223062 - Fhatika Adhalisman Ryanjani	• Membuat laporan • Mengerjakan PPT
18223070 - Muhammad Refino Ramadhan	• Membuat front-end website • Mengerjakan PPT